

Valtti Järvi

FOUNDATIONAL TIME SERIES MODELS FOR EMERGENCY DEPARTMENT OCCUPANCY FORECASTING

Kandidaatin tutkielma
Informaatioteknologian ja viestinnän tiedekunta
Tarkastaja: Etunimi Sukunimi
Lokakuu 2025

SISÄLLYSLUETTELO

1. Introduction	5
2. Background	5
2.1 Emergency department	5
2.1.1 Definition of crowding	5
2.1.2 Consequences of crowding	5
2.1.3 Emergency department forecasting	5
2.2 Time series forecasting.	5
2.3 Foundational models	5
2.3.1 Pre-training and fine-tuning paradigm	5
2.3.2 Selected foundational time series models	5
3. Methodology	5
3.1 Data	5
3.2 Experimental setup	5
3.3 Evaluation	5
3.4 Models	5
3.4.1 Chronos	5
3.4.2 TimesFM.	5
3.4.3 Moirai	5
3.4.4 Sundial	5
3.4.5 TiRex	5
3.4.6 Benchmark models.	5
4. Results and Discussion	5
4.1 Predictive performance.	5
4.2 Effect of context length	5
4.3 Effect of covariates	5
4.4 Computational cost	5
4.5 Limitations.	5
5. Conclusion	5
6. References.	6
Appendix A: Computational costs for multivariate forecasts	8

Aikasarjaennustaminen

Aikasarjaennustamisen tavoitteena on ennustaa datajonon tulevaa kehitystä sen menneiden arvojen perusteella. Ulkoisia datajonoja voidaan sisällyttää tarkempien ennusteiden saamiseksi. [1] Esimerkiksi tässä työssä käsiteltävää päivystyksen tulevaa tuntikohtaista kuormitusta voidaan ennustaa käyttämällä menneitä kuormitustietoja, kalenteritietoja ja sää tietoja.

Diskreettiaikainen aikasarja on joukko diskreettejä arvoja $\{x_t\}$, missä t tarkoittaa tiettyä ajanhetkeä. Aikavälit $t:n$ arvojen välillä ovat yleensä kiinteitä ja samanpituisia. Termi yksimuuttuja (eng. univariate) viittaa dataan, joka koostuu yhdestä piirteestä tai muuttujasta. Sitä vastoin termi monimuuttuja (eng. multivariate) viittaa dataan, joka koostuu useista toisiinsa liittyvistä muuttujista. Näiden muuttujien väliset suhteet voivat tarjota lisätietoa ennustamiseen. Monimuuttujien joukkoa voidaan merkitä muodossa $\{\mathbf{x}_t\}$, missä $\mathbf{x}_t$ on vektori. Muita muuttujia kuin ennustettavaa muuttujaa kutsutaan kovariaateiksi tai eksogeenisiksi syötteiksi. [2]

Jotta aikasarjasta voidaan ennustaa tulevaisuuden arvoja, siinä on oltava tunnistettavissa olevia kuvioita. Trendikomponentti edustaa datan pitkän aikavälin suuntaa tai asteittaista muutosta, mikä päivystyskuormitusdatan tapauksessa voi heijastaa esimerkiksi väestönkasvua. Kausivaihtelu tarkoittaa säännöllisin väliajoin toistuvia kuvioita. Esimerkiksi päivystyksen kuormitus on huipussaan päivittäin klo 16:00–19:00 ja alimmillaan klo 04:00–07:00 [3]. Satunnaiskohina viittaa epäsäännöllisiin ja satunnaisiin vaihteluihin, joita ei voida selittää millään kuviolla. Loppujen lopuksi monet asiat, kuten onnettomuudet, tapahtuvat sattumanvaraisesti. Nämä ja monet muut kuviot, mukaan lukien kovariaattien kuviot, tekevät ennustamisesta mahdollista. [2]

Matemaattista yhtälöä, joka kuvaa datasta löytyviä kuvioita kutsutaan *Malliksi*. Tavoitteena on löytää malli, joka kuvaa tehokkaasti aikasarjan perusrakennetta. Tämä suhde voidaan ilmaista muodollisesti yleisellä yhtälöllä:

$$y_{t+1} = f(y_t, y_{t-1}, \dots, \mathbf{x}_{t+1}, \mathbf{x}_t, \dots) + \epsilon_{t+1} \quad (1)$$

Funktio f edustaa itse mallia. Se määrittelee suhteen kohdemuuttujan y_{t+1} ja kohdemuuttujan menneiden arvojen $y_t, y_{t-1}, \dots$ sekä kovariaattien $\mathbf{x}_t, \mathbf{x}_{t-1}, \dots$ nykyisten ja menneiden arvojen välillä. Termi ϵ_t on satunnaiskohinaa, jota malli ei kykene selittämään. Malli f voi olla yksinkertainen tilastollinen malli tai monimutkaisempi koneoppimismalli, kuten neuroverkko. [1]

Tulevaisuus on aina jossain määrin arvaamaton. Siksi pelkän yksittäisen arvon ennustamisen sijaan on usein hyödyllistä ennustaa tulevan arvon koko todennäköisyysjakauma. Tätä kutsutaan ennustejakaumaksi. Ennustevälit edustavat arvoaluetta, jonka sisällä tuleva arvo tietyllä todennäköisyydellä on. Esimerkiksi 90 %:n ennusteväli sisältää todellisen arvon

90 %:n todennäköisyydellä. Sitä vastoin piste-ennuste edustaa parasta yksittäistä arviota tulevasta arvosta. Se on usein ennustejakauman keskiarvo tai mediaani. [1]

Perustamallit

Perustamallit ovat tekoälyjärjestelmiä, jotka kykenevät suorittamaan hyvin useita erilaisia tehtäviä. Nämä mallit koulutetaan massiivisilla ja monipuolisilla data-aineistoilla. Perustamallit käyttävät syviä neuroverkkoarkkitehtuuria, joiden parametrien määrä vaihtelee sadoista miljoonista satoihin miljardeihin sovellusalueesta riippuen. [4] Esimerkiksi aikasarjojen ennustamiseen on kehitetty perustamalleja, ja yksi perustamalli voi ennustaa monenlaisia aikasarjoja päivystyksen kuormituksesta osakekursseihin.

Perustamallit eroavat perinteisistä koneoppimismalleista, jotka koulutetaan yhtä tiettyä tehtävää varten. Perinteinen koneoppimismalli voidaan esimerkiksi kouluttaa ennustamaan vain yhden tietyn sairaalan päivystyskuormitusta. Laskentatehon kehitys on mahdollistanut suurempien mallien kouluttamisen useita eri tarkoituksia varten. [4]

Siirto-oppiminen on koneoppimiseen liittyvä käsite, jossa yhdessä opitusta tehtävästä siirretään tietoa muihin tehtäviin [5]. Laajoista koulutusaineistoista opitaan perustavanlaatuisia rakenteita, jotka pätevät kaikkiin saman alan tehtäviin [5]. Esimerkiksi päivystyksen kuormituksella ja osakekursseilla voi olla samankaltainen päivittäinen vaihtelu. Siirto-oppiminen ja perustamallien valtava koko ovat avain niiden toimivuuteen [4].

Julkaisussa [4] kirjoittajat nimeävät kolme edistysaskelta, jotka ovat mahdollistaneet perustamallien koon kasvun: laskentalaitteistojen kehitys, Transformer-arkkitehtuuri, joka hyödyntää tehokkaasti tätä laitteistoa koulutuksessa [6], sekä laajempien data-aineistojen saatavuus.

Mallien koulutus ja soveltaminen

Syväoppiminen on koneoppimisen osa-alue, joka käyttää syviä neuroverkkoja datasta oppimiseen. Nämä verkot oppivat datan esitysmuotoja useilla tasoilla [7]. Syväoppiminen on useimpien nykyaikaisten tekoälymallien taustalla.

Julkaisussa [8] kirjoittaja esittää kolme keskeistä näkökohtaa koneoppimismallien kehittämisessä. Ensimmäinen vaihe on esitysmuodon eli mallin valinta. Syväoppimisen tapauksessa tämä tehdään valitsemalla mallin arkkitehtuuri. Sitten malli optimoidaan eli koulutetaan sovittumaan dataan. Koulutus tapahtuu säätämällä mallin parametreja häviöfunktion minimoimiseksi. Tämä vaihe on laskennallisesti raskas ja vaatii usein massiivisia datakeskuksia ja merkittävästi aikaa. [4] Viimeinen vaihe on arviointi, jossa mallin suorituskyky mitataan datalla, jota ei ole nähty koulutuksen aikana. Syväoppiminen noudattaa tätä viitekehystä [7].

Perustamallit käyttävät erilaista viitekehystä ja edustavat paradigman muutosta perinteiseen koneoppimisen viitekehykseen. Tiettyä tehtävää varten voidaan valita jo esikoulutettu perustamalli. Perustamalli hienosäädetään usein tiettyä tehtävää varten. Viimeinen perustamallien viitekehysten vaihe on mallin arviointi. [4]

Tämä lähestymistapa säästää merkittävästi laskentaa, aikaa ja vaivaa, koska perustamalli on jo esikoulutettu. Se madaltaa kynnystä käyttää edistyneitä tekoälymalleja. Päivystyskuormituksen ennustamisessa jokaisella sairaalalla on omat erityispiirteensä. Siksi yhden sairaalan malli toimisi huonosti toisissa sairaaloissa. Erillisen mallin kouluttaminen jokaiselle sairaalalle olisi kallista. Perustamallit voivat ratkaista tämän ongelman.

- [1] Hyndman, R. J. ja Athanasopoulos, G. *Forecasting: Principles and Practice*. 2. painos. Melbourne, Australia: OTexts, 2018.
- [2] Peter J. Brockwell, R. A. D. *Introduction to Time Series and Forecasting*. 2016. DOI: 10.1007/978-3-319-29854-2.
- [3] Tuominen, J., Pulkkinen, E., Peltonen, J., Kanninen, J., Oksala, N., Palomäki, A. ja Roine, A. Forecasting emergency department occupancy with advanced machine learning models and multivariable input. *International Journal of Forecasting* 40.4 (1. lokakuuta 2024), s. 1410–1420. DOI: 10.1016/j.ijforecast.2023.12.002.
- [4] Bommasani, R. et al. *On the Opportunities and Risks of Foundation Models*. 2022. arXiv: 2108.07258 [cs.LG].
- [5] Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W. ja Liu, P. J. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. *The Journal of Machine Learning Research* 21.140 (2020), s. 1–67.
- [6] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. ja Polosukhin, I. Attention Is All You Need. *Advances in Neural Information Processing Systems*. 2017, s. 5998–6008.
- [7] LeCun, Y., Bengio, Y. ja Hinton, G. Deep Learning. *Nature* 521.7553 (2015), s. 436–444. DOI: 10.1038/nature14539.
- [8] Domingos, P. A Few Useful Things to Know About Machine Learning. *Communications of the ACM* 55.10 (2012), s. 78–87. DOI: 10.1145/2347736.2347755.
- [9] Sartini, M., Carbone, A., Demartini, A., Giribone, L., Oliva, M., Spagnolo, A. M., Cremonesi, P., Canale, F. ja Cristina, M. L. Overcrowding in Emergency Department: Causes, Consequences, and Solutions—A Narrative Review. *Healthcare* 10.9 (25. elokuuta 2022), s. 1625. DOI: 10.3390/healthcare10091625.
- [10] Jo, S., Jin, Y. H., Lee, J. B., Jeong, T., Yoon, J. ja Park, B. Emergency Department Occupancy Ratio is Associated With Increased Early Mortality. *Journal of Emergency Medicine* 46.2 (1. helmikuuta 2014), s. 241–249. DOI: 10.1016/j.jemermed.2013.05.026.
- [11] McCarthy, M. L., Zeger, S. L., Ding, R., Levin, S. R., Desmond, J. S., Lee, J. ja Aronsky, D. Crowding Delays Treatment and Lengthens Emergency Department Length of Stay, Even Among High-Acuity Patients. *Annals of Emergency Medicine* 54.4 (1. lokakuuta 2009), 492–503.e4. DOI: 10.1016/j.annemergmed.2009.03.006.
- [12] Hwang, U., McCarthy, M. L., Aronsky, D., Asplin, B., Crane, P. W., Craven, C. K., Epstein, S. K., Fee, C., Handel, D. A., Pines, J. M. et al. Measures of crowding in the emergency department: a systematic review. *Academic Emergency Medicine* 18.5 (2011), s. 527–538.
- [13] Asplin, B. R., Magid, D. J., Rhodes, K. V., Solberg, L. I., Lurie, N. ja Camargo Jr, C. A. A conceptual model of emergency department crowding. *Annals of emergency medicine* 42.2 (2003), s. 173–180.

- [14] Richardson, D. B. Increase in patient mortality at 10 days associated with emergency department overcrowding. Englanti. *The Medical Journal of Australia* 184.5 (6. maaliskuuta 2006), s. 213–216. DOI: 10.5694/j.1326-5377.2006.tb00204.x.
- [15] Guttman, A., Schull, M. J., Vermeulen, M. J. ja Stukel, T. A. Association between waiting times and short term mortality and hospital admission after departure from emergency department: population based cohort study from Ontario, Canada. *BMJ* 342 (2011). DOI: 10.1136/bmj.d2983. eprint: <https://www.bmj.com/content/342/bmj.d2983.full.pdf>.
- [16] Eidstø, A., Ylä-Mattila, J., Tuominen, J., Huhtala, H., Palomäki, A. ja Koivistoinen, T. Emergency department crowding increases 10-day mortality for non-critical patients: a retrospective observational study. *Internal and Emergency Medicine* 19.1 (2024), s. 175–181.
- [17] Kulstad, E. B., Sikka, R., Sweis, R. T., Kelley, K. M. ja Rzechula, K. H. ED overcrowding is associated with an increased frequency of medication errors. *The American Journal of Emergency Medicine* 28.3 (2010), s. 304–309. DOI: <https://doi.org/10.1016/j.ajem.2008.12.014>.
- [18] Bond, K., Ospina, M., Blitz, S., Afilalo, M., Sam, G., Bullard, M., Innes, G., Holroyd, B., Curry, G., Schull, M. ja Rowe, B. Frequency, Determinants and Impact of Overcrowding in Emergency Departments in Canada: A National Survey. *Healthcare quarterly (Toronto, Ont.)* 10 (helmikuu 2007), s. 32–40. DOI: 10.12927/hcq.2007.19312.
- [19] Gul, M. ja Celik, E. An exhaustive review and analysis on applications of statistical forecasting in hospital emergency departments. *Health Systems* 9.4 (2018), s. 263–284. DOI: 10.1080/20476965.2018.1547348.
- [20] *Canadian Journal of Emergency Medicine* 3.2 (2001), s. 82–84. DOI: 10.1017/S1481803500005285.
- [21] Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Arango, S. P., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M. ja Wang, Y. *Chronos: Learning the Language of Time Series*. 4. marraskuuta 2024. DOI: 10.48550/arXiv.2403.07815. arXiv: 2403.07815.
- [22] Auer, A., Podest, P., Klotz, D., Böck, S., Klambauer, G. ja Hochreiter, S. *TiRex: Zero-Shot Forecasting Across Long and Short Horizons with Enhanced In-Context Learning*. 29. toukokuuta 2025. DOI: 10.48550/arXiv.2505.23719. arXiv: 2505.23719.
- [23] Das, A., Kong, W., Sen, R. ja Zhou, Y. *A decoder-only foundation model for time-series forecasting*. 17. huhtikuuta 2024. DOI: 10.48550/arXiv.2310.10688. arXiv: 2310.10688.
- [24] Liu, Y., Qin, G., Shi, Z., Chen, Z., Yang, C., Huang, X., Wang, J. ja Long, M. *Sundial: A Family of Highly Capable Time Series Foundation Models*. 30. toukokuuta 2025. DOI: 10.48550/arXiv.2502.00816. arXiv: 2502.00816.

- [25] Woo, G., Liu, C., Kumar, A., Xiong, C., Savarese, S. ja Sahoo, D. *Unified Training of Universal Time Series Forecasting Transformers*. 22. toukokuuta 2024. DOI: 10.48550/arXiv.2402.02592. arXiv: 2402.02592.
- [26] Berg, L. M., Ehrenberg, A., Florin, J., Östergren, J., Discacciati, A. ja Göransson, K. E. Associations Between Crowding and Ten-Day Mortality Among Patients Allocated Lower Triage Acuity Levels Without Need of Acute Hospital Care on Departure From the Emergency Department. *Annals of Emergency Medicine* 74.3 (1. syyskuuta 2019), s. 345–356. DOI: 10.1016/j.annemergmed.2019.04.012.
- [27] Bernstein, S. L., Aronsky, D., Duseja, R., Epstein, S., Handel, D., Hwang, U., McCarthy, M., McConnell, K. J., Pines, J. M., Rathlev, N., Schafermeyer, R., Zwemer, F., Schull, M. ja Asplin, B. R. Emergency Department Crowding, Part 1: Definition and Magnitude. *Academic Emergency Medicine* 16.11 (2009), s. 106–113. DOI: 10.1111/j.1553-2712.2009.00590.x.
- [28] Koya, S. R. ja Roy, T. Temporal Fusion Transformers for Streamflow Prediction: Value of Combining Attention with Recurrence. *Journal of Hydrology* 637 (2024), s. 131301.
- [29] Jin, M., Wen, Q., Liang, Y., Zhang, C., Xue, S., Wang, X., Zhang, J., Wang, Y., Chen, H., Li, X. et al. Foundation Models for Time Series Analysis: A Tutorial and Survey. *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2024, s. 6407–6416.
- [30] Beck, M., Pöppel, K., Spanring, M., Auer, A., Prudnikova, O., Kopp, M. K., Klambauer, G., Brandstetter, J. ja Hochreiter, S. xLSTM: Extended Long Short-Term Memory. *The Thirty-eighth Annual Conference on Neural Information Processing Systems*. Marraskuu 2024.
- [31] Lim, B., Arik, S. Ö., Loeff, N. ja Pfister, T. Temporal Fusion Transformer for Interpretable Multi-horizon Time Series Forecasting. *arXiv preprint arXiv:1912.09363* (2021).
- [32] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. ja Liu, T.-Y. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*. Vol. 30. 2017, s. 3146–3154.
- [33] Friedman, J. H. Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics* 29.5 (2001), s. 1189–1232. DOI: 10.1214/aos/1013203451.
- [34] Aksu, T., Woo, G., Liu, J., Liu, X., Liu, C., Savarese, S., Xiong, C. ja Sahoo, D. GIFT-Eval: A Benchmark For General Time Series Forecasting Model Evaluation. *arXiv preprint arXiv:2410.10393* (2024).
- [35] Salesforce AI Research. *GIFT-Eval Leaderboard: General Time Series Forecasting Model Evaluation*. <https://huggingface.co/spaces/Salesforce/GIFT-Eval>. 2024.
- [36] Salesforce AI Research. *Introducing Moirai 2.0*. <https://www.salesforce.com/blog/moirai-2-0/>. 2025.